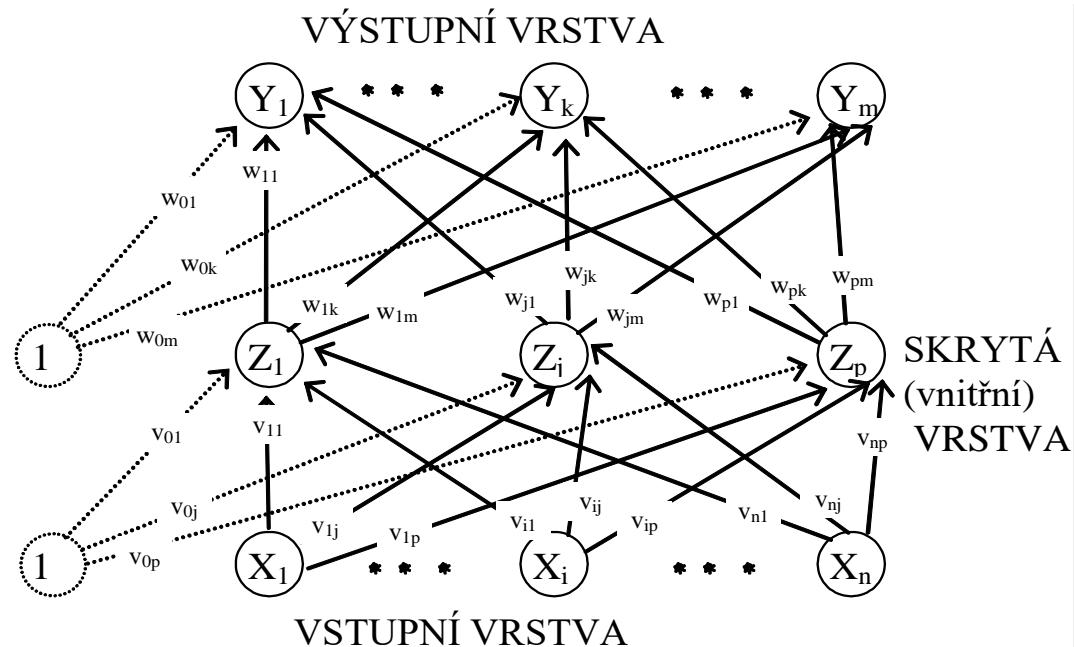


Backpropagation

odvození adaptačního pravidla

Topologie vícevrstvé sítě

Vícevrstvá neuronová síť je tvořena minimálně třemi vrstvami neuronů: **vstupní**, **výstupní** a alespoň jednou **vnitřní** vrstvou. Vždy mezi dvěma sousedními vrstvami se pak nachází tzv. *úplné propojení neuronů*, tedy každý **neuron nižší vrstvy** je spojen se **všemi neuronami vrstvy vyšší**.



Bias odpovídá váhové hodnotě přiřazené spojení mezi daným neuronem a fiktivním neuronem, jehož aktivace je vždy 1.

Standardní metoda backpropagation

Adaptační algoritmus **zpětného šíření chyby**
(backpropagation).

Samotný algoritmus obsahuje tři etapy:

- dopředné (*feedforward*) šíření vstupního signálu tréninkového vzoru
- zpětné šíření chyby
- aktualizace váhových hodnot na spojeních

Adaptační algoritmus backpropagation

Krok 0. Váhové hodnoty a bias jsou inicializovány malými náhodnými čísly.

Přiřazení inicializační hodnoty koeficientu učení α .

Krok 1. Dokud není splněna **podmínka ukončení výpočtu**, opakovat kroky (2 až 9).



Podmínka ukončení:

pokud již nenastávají žádné změny váhových hodnot nebo pokud již bylo vykonáno maximálně definované množství váhových změn, stop; jinak, pokračovat.

Feedforward:

Krok 3. Aktivovat vstupní neurony (X_i , $i=1, \dots, n$)

$$x_i = s_i..$$

Krok 4 Vypočítat vstupní hodnoty vnitřních neuronů:

$$(Z_j, j=1, \dots, p):$$

$$z_{in_j} = v_{0j} + \sum_{i=1}^n x_i v_{ij}.$$

Stanovení výstupních hodnot vnitřních neuronů

$$z_j = f(z_{in_j}).$$

Krok 5 Stanovení skutečných výstupních hodnoty signálu
neuronové sítě (Y_k , $k=1, \dots, m$):

$$y_{in_k} = w_{0k} + \sum_{j=1}^p z_j w_{jk},$$

$$y_k = f(y_{in_k}).$$

Backpropagation:

- Krok 6* Ke každému neuronu ve výstupní vrstvě ($Y_k, k=1, \dots, m$) je přiřazena hodnota očekávaného výstupu pro vstupní tréninkový vzor. Dále je vypočteno $\delta_k = (t_k - y_k) f'(y_{in_k})$, které je součástí váhové korekce $\Delta w_{j,k} = \alpha \delta_k z_j$ i korekce biasu $\Delta w_{0,k} = \alpha \delta_k$.

- Krok 7* Ke každému neuronu ve vnitřní vrstvě ($Z_j, j=1, \dots, p$) je přiřazena sumace jeho delta vstupů (tj. z neuronů, které se nacházejí v následující vrstvě),

$$\delta_{in_j} = \sum_{k=1}^m \delta_k w_{j,k}. \text{ Vynásobením získaných hodnot}$$

derivací jejich aktivační funkce obdržíme

$$\delta_j = \delta_{in_j} f'(z_{in_j}), \text{ které je součástí váhové korekce} \\ \Delta v_{i,j} = \alpha \delta_j x_i \text{ i korekce biasu } \Delta v_{0,j} = \alpha \delta_j.$$

Aktualizace vah a prahů:

Krok 8 Každý neuron ve výstupní vrstvě ($Y_k, k=1, \dots, m$) aktualizuje na svých spojeních váhové hodnoty včetně svého biasu ($j=0, \dots, p$):

$$w_{j,k}(\text{new}) = w_{j,k}(\text{old}) + \Delta w_{j,k}.$$

Každý neuron ve vnitřní vrstvě ($Z_j, j=1, \dots, p$) aktualizuje na svých spojeních váhové hodnoty včetně svého biasu ($i=0, \dots, n$):

$$v_{i,j}(\text{new}) = v_{i,j}(\text{old}) + \Delta v_{i,j}.$$

Krok 9. Podmínka ukončení:
pokud již nenastávají žádné změny váhových hodnot nebo pokud již bylo vykonáno maximálně definované množství váhových změn, stop; jinak, pokračovat.

Trénovací množina

$$T = \{[x_1, t_1], \dots, [x_p, t_p]\}$$

$x_j = (x_{1j}, \dots, x_{nj})$ vstupní vektor $j.$ vzoru

$t_j = (t_{1j}, \dots, t_{mj})$ výstupní vektor $j.$ vzoru

p počet vzorů trénovací množiny

Chyba neuronové sítě

$$E = \frac{1}{2} \sum_{j=1}^p \sum_{i=1}^m (y_{ij} - t_{ij})^2$$

$y_j = (y_{1j}, \dots, y_{mj})$ skutečný výstupní vektor $j.$ vzoru

$t_j = (t_{1j}, \dots, t_{mj})$ požadovaný výstupní vektor $j.$ vzoru

Přírůstky vah

$$\Delta w_i = -\alpha \frac{\partial E}{\partial w_i} + \mu \Delta w_i^{'},$$

α koeficient učení z intervalu $(0,1)$

μ koeficient setrvačnosti - momentum
z intervalu $\langle 0,1 \rangle$

$\Delta w_i^{'}$ změna váhy v předchozím kroku

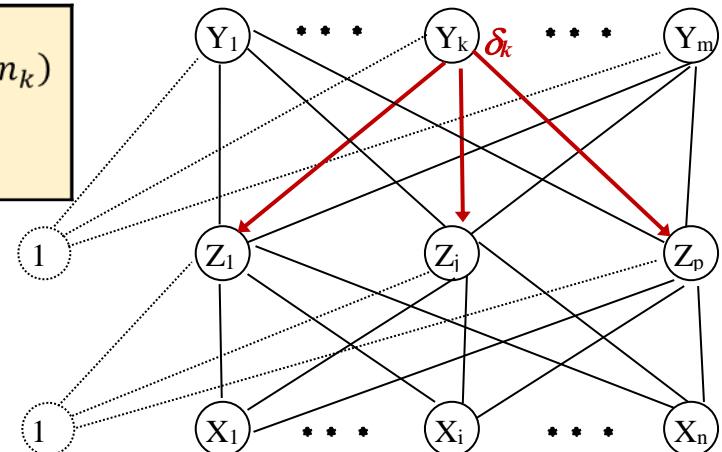
- $\frac{\partial E}{\partial w_i} = \frac{\partial E}{\partial y} \cdot \frac{\partial y}{\partial y_in} \cdot \frac{\partial y_in}{\partial w_i}$
- $E = \frac{1}{2}(y_i - t_i)^2$ chyba pro $i.$ výstupní neuron
- $y = \frac{1}{1+e^{-\lambda \cdot y_in}} = (1 + e^{-\lambda \cdot y_in})^{-1}$ aktivační (přenosová) funkce – logická sigmoida (λ je parametr strmost sigmoidy)
- $y_in = \sum_i x_i \cdot w_i$ vnitřní potenciál neuronu
.... jedna složka $y_in = x_i \cdot w_i$

Přírůstky vah mezi vnitřní a výstupní vrstvou:

$$\frac{\partial E}{\partial w_i} = \frac{\partial E}{\partial y} \cdot \frac{\partial y}{\partial y_in} \cdot \frac{\partial y_in}{\partial w_i}$$

SKRIPTA:
 $\delta_k = (t_k - y_k) \cdot f'(y_in_k)$
 $\Delta w_{jk} = \alpha \cdot \delta_k \cdot z_j$

$$\frac{\partial E}{\partial y} = (y - t)$$



$$\frac{\partial y}{\partial y_in} = -1 \cdot (1 + e^{-\lambda \cdot y_in})^{-2} \cdot e^{-\lambda \cdot y_in} \cdot (-\lambda)$$

$$= \lambda \cdot \frac{e^{-\lambda \cdot y_in} + 1 - 1}{(1 + e^{-\lambda \cdot y_in})^2} = \lambda \cdot \left(\frac{(1 + e^{-\lambda \cdot y_in})}{(1 + e^{-\lambda \cdot y_in})^2} - \frac{1}{(1 + e^{-\lambda \cdot y_in})^2} \right)$$

$$= \lambda \cdot (y - y^2) = \lambda \cdot y \cdot (1 - y)$$

$$\frac{\partial y_in}{\partial w_i} = x_i$$

$$\Delta w_i = -\alpha \cdot (y - t) \cdot \lambda \cdot y \cdot (1 - y) \cdot x_i$$

$$\Delta w_{jk} = \alpha \cdot (t_k - y_k) \cdot \lambda \cdot y \cdot (1 - y) \cdot z_j$$

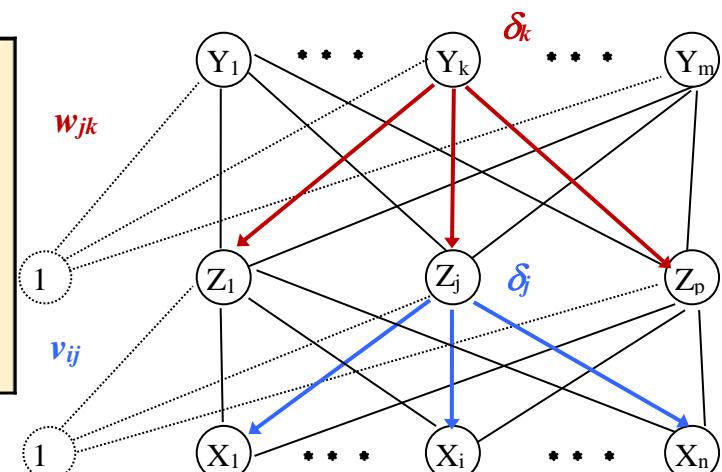
Přírůstky vah mezi vstupní a vnitřní vrstvou:

$$\frac{\partial E}{\partial w_i} = \frac{\partial E}{\partial y} \cdot \frac{\partial y}{\partial y_in} \cdot \frac{\partial y_in}{\partial w_i}$$

SKRIPTA:

$$\delta_in_j = \sum_{k=1}^m \delta_k \cdot w_{jk}$$

$$\delta_j = \delta_in_j \cdot f'(z_{in_j})$$

$$\Delta v_{ij} = \alpha \cdot \delta_j \cdot x_i$$


$$\begin{aligned} \frac{\partial E}{\partial y} &= \sum_{i=1}^m \frac{\partial E}{\partial y_in_i} \cdot \frac{\partial y_in_i}{\partial y} = \sum_{i=1}^m \frac{\partial E}{\partial y} \cdot \frac{\partial y}{\partial y_in_i} \cdot \frac{\partial y_in_i}{\partial y} = \sum_{i=1}^m \frac{\partial E}{\partial y} \cdot \frac{\partial y}{\partial y_in_i} \cdot w_i \\ &= \sum_{i=1}^m (y_i - t_i) \cdot \lambda \cdot y_i \cdot (1 - y_i) \cdot w_i \end{aligned}$$

$$\frac{\partial y}{\partial y_in} = \lambda \cdot z \cdot (1 - z) \quad \frac{\partial y_in}{\partial w_i} = x_i$$

$$\Delta w_i = -\alpha \cdot \left(\sum_{i=1}^m (y_i - t_i) \cdot \lambda \cdot y_i \cdot (1 - y_i) \cdot w_i \right) \lambda \cdot z \cdot (1 - z) \cdot x_i$$

$$\Delta v_{ij} = \alpha \cdot \left(\sum_{k=1}^m (t_k - y_k) \cdot \lambda \cdot y_k \cdot (1 - y_k) \cdot w_{kj} \right) \lambda \cdot z_j \cdot (1 - z_j) \cdot x_i$$